

Relatório Técnico: Triagem Semântica de Manifestações Cidadãs – Ouvidoria Inteligente

Projeto: Sistema de Triagem Semântica baseado em Processamento de Linguagem Natural (NLP)

Modelo Principal Utilizado: paraphrase-multilingual-MiniLM-L12-v2

Objetivo: Modernizar a triagem de manifestações da Ouvidoria Geral, substituindo a busca por palavras-chave por busca semântica vetorial.

1. Análise Comparativa de Representações (Entrega 1)

O primeiro estágio do projeto consistiu em avaliar o comportamento de representações esparsas (Bag of Words e TF-IDF) em comparação com representações densas (Embeddings) ao calcular a similaridade de cosseno entre pares de manifestações.

- **Limitações do BoW e TF-IDF:** Ambas as técnicas esparsas demonstraram severas limitações ao lidar com a variação vocabular. Ao comparar "buraco enorme na Av. Brasil" (M003) com "asfalto todo esburacado da avenida principal" (M017), os modelos clássicos retornaram similaridade próxima a zero, pois baseiam-se na correspondência exata de tokens. O mesmo ocorreu no par abordando saúde pública ("sem médico" vs. "falta atendimento").
- **Vantagem dos Embeddings:** O modelo paraphrase-multilingual-MiniLM-L12-v2 obteve sucesso ao mapear textos semanticamente semelhantes para regiões próximas no espaço vetorial, independentemente das palavras exatas utilizadas. Ele atribuiu alta similaridade aos pares M003xM017 e M008xM022, provando ser a arquitetura adequada para capturar a intenção real do cidadão. Adicionalmente, conseguiu isolar corretamente denúncias não relacionadas (posto sem médico vs. lâmpada queimada).

2. Detecção de Duplicatas (Entrega 2)

A base de dados da ouvidoria contém cerca de 15% de manifestações redundantes. Para automatizar a identificação dessas duplicatas, foi implementada uma matriz de similaridade de cosseno cobrindo todo o corpus.

- **Definição do Limiar (Threshold):** Optou-se por um limiar conservador de **0.85**.
- **Análise de Falsos Positivos e Negativos:** Em testes preliminares, valores abaixo de 0.80 tenderam a gerar falsos positivos, agrupando problemas genéricos da mesma categoria (ex: dois buracos em bairros distintos). Valores acima de 0.90 mostraram-se rígidos demais, gerando falsos negativos ao excluir duplicatas onde o cidadão utilizou uma estrutura gramatical levemente diferente. O limiar de 0.85

equilibrou a precisão, identificando corretamente os pares repetidos sem mesclar denúncias independentes.

3. Estratégias de Chunking para Manifestações Longas (Entrega 3)

Para resolver o problema da perda de contexto em manifestações com mais de 500 caracteres, aplicou-se a técnica de divisão de textos (*chunking*) utilizando o `RecursiveCharacterTextSplitter`.

- **Configuração Escolhida:** A configuração ideal encontrada foi `chunk_size = 250` e `chunk_overlap = 50`.
- **Importância da Sobreposição (Overlap):** Testes com baixo *overlap* demonstraram que frases cortadas abruptamente perdem a coesão. Por exemplo, se a menção ao "acúmulo de lixo" ficar em um chunk e a consequência "atraindo insetos" ficar no próximo, a busca semântica sofre degradação. Uma sobreposição de 50 caracteres garantiu que o sujeito da denúncia e o problema relatado estivessem presentes simultaneamente em pelo menos uma das divisões.
- **Validação no Espaço Vetorial:** Ao projetar os chunks das manifestações longas em 2D usando PCA, observou-se que os pedaços derivados de um mesmo texto original formaram agrupamentos próximos (clusters), comprovando que o sentido geral da denúncia foi preservado após o fatiamento.

4. Visualização e Buscador Semântico (Entrega 4)

O protótipo final foi consolidado em uma aplicação interativa com Streamlit, contemplando o buscador semântico e a projeção visual da base de dados.

- **Comportamento do Buscador:** O buscador opera calculando o embedding da *query* do usuário e comparando-o com a base pré-computada. Implementou-se um sistema de semáforo (Verde > 0.7, Amarelo > 0.5, Vermelho < 0.5) para indicar o grau de confiança da busca.
- **Clusters no Espaço Vetorial:** A visualização em 2D (via PCA) evidenciou que as manifestações tendem a formar aglomerados naturais de acordo com suas categorias oficiais (Saúde, Segurança, Educação, etc.). Contudo, notou-se uma sobreposição natural entre as categorias "Meio Ambiente" e "Infraestrutura", o que é coerente com a realidade urbana, visto que denúncias sobre terrenos baldios ou entulhos na via pública cruzam a fronteira entre esses dois domínios.

5. Dificuldades Encontradas e Aprendizados

A principal dificuldade técnica enfrentada durante a validação da ferramenta ocorreu na etapa de busca do Streamlit. Quando testes iniciais foram feitos inserindo apenas palavras-chave soltas (como "buraco"), o modelo de embedding retornou *scores* baixos de similaridade geométrica (frequentemente abaixo de 0.50).

Isso gerou o aprendizado crítico de que modelos baseados em *Sentence-Transformers* são otimizados para comparar o significado e a distribuição vetorial de sentenças completas. Ao substituir buscas curtas por descrições ricas e contextuais (ex: "tem uma cratera na rua que estragou meu pneu"), a similaridade subiu drasticamente. Este comportamento confirmou o sucesso do projeto: o sistema penaliza buscas engessadas do sistema antigo e recompensa descrições naturais, atingindo exatamente o objetivo de criar uma Ouvidoria pautada pela semântica.